

OBJECTIFS PÉDAGOGIQUES :

- Calculer les coordonnées du point moyen d'un nuage de point de série à deux caractères.
- Déterminer une équation cartésienne de la droite d'ajustement par la méthode de MAYER, puis utiliser pour donner approximativement en prévision la valeur d'une variable connaissant celle de l'autre.
- Calculer la covariance, le coefficient de corrélation d'une série.
- Déterminer les équations des droites de régressions par la méthode des moindres carrées.
- Apprécier la qualité de la corrélation entre deux variables d'une série double, puis donner approximativement en prévision la valeur d'une variable connaissant celle de l'autre.

SITUATION PROBLEME :

Afin d'orienter ses investissements, une chaine d'hôtel réalise des analyses sur le taux d'occupation des chambres. Une analyse établit un lien entre le taux d'occupation (en%) et le montant de publicité (en milliers FCFA).

Frais de publicité (x_i)	30	27	32	25	35	22	24	35
Taux d'occupation (y_j)	52	45	67	55	76	48	32	72

Quelle estimation peut-on faire du taux d'occupation des chambres de cet hôtel si les frais de publicité étaient de 4000000FCFA ?

PRE-REQUIS :

- 1) Déterminer une équation de la droite passant par les points $A\begin{pmatrix} -3 \\ -4 \end{pmatrix}$ et $B\begin{pmatrix} 1 \\ 2 \end{pmatrix}$ puis vérifier si le $C\begin{pmatrix} 3 \\ 1 \end{pmatrix}$ appartient à cette droite.
- 2) Les notes en mathématiques de la cinquième séquence des élèves d'une classe de terminale C sont représentées dans le tableau suivant :

Notes	04	05	06	07	08	09	10	11	12	13	14	15	16	17
effectifs	3	1	2	5	5	4	2	4	3	4	2	2	1	2

Calculer la moyenne et la variance de cette série.

ACTIVITE D'APPRENTISSAGE :

Afin d'orienter ses investissements, une chaine d'hôtel réalise des analyse sur le taux d'occupation des chambres. Une analyse établit un lien entre le taux d'occupation (en%) et le montant de publicité (en milliers FCFA).

Frais de publicité (x_i)	30	27	32	25	35	22	24	35
Taux d'occupation (y_j)	52	45	67	55	76	48	32	72

- 1) Calculer la moyenne $\bar{x}$ suivant la variable x et la moyenne $\bar{y}$ suivant la variable y .
- 2) Calculer la variance V_x suivant la variable x et la variance V_y suivant la variable y .
- 3) Ranger le tableau dans l'ordre croissant des x_i puis calculer $\bar{x}_1$ et $\bar{y}_1$ qui est la moyenne des quatre premières colonnes ainsi $\bar{x}_2$ et $\bar{y}_2$ la moyenne du reste des colonnes.
- 4) Soit les points $G_1(\bar{x}_1; \bar{y}_1)$ et $G_2(\bar{x}_2; \bar{y}_2)$; déterminer une équation de droite qui passe par les points G_1 et G_2 .
- 5) Calculer $p = \frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{x} \bar{y}$; $r = \frac{p}{\sqrt{V_x \times V_y}}$, où n est nombre de colonne.
- 6) Déterminer une équation de la droite de la forme $y = ax + b$; avec $a = \frac{p}{V_x}$ et $b = \bar{y} - a\bar{x}$.
- 7) Quelle estimation peut-on faire du taux d'occupation des chambres de cet hôtel si les frais de publicité étaient de 4000000FCFA.

Solutions :

									total
x_i	30	27	32	25	35	22	24	35	230
y_i	52	45	67	55	76	48	32	72	447
x_i^2	900	729	1024	625	1225	484	576	1225	6788
y_i^2	2704	2025	4489	3025	5776	2304	1024	5184	26531
$x_i \times y_i$	1560	1215	2144	1375	2660	1056	768	2520	13298

- 1) Calculons la moyenne :
$$\bar{x} = \frac{1}{8} \sum x_i = \frac{230}{8} = 28,75 \text{ et } \bar{y} = \frac{1}{8} \sum y_i = \frac{447}{8} = 55,88$$
- 2) Déterminons la variance de x et y .
$$V_x = \frac{1}{8} \sum x_i^2 - \bar{x}^2 = \frac{6788}{8} - (28,75)^2 = 21,94 \text{ et } V_y = \frac{1}{8} \sum y_i^2 - \bar{y}^2 = \frac{26531}{8} - (55,88)^2 = 193,80$$
- 3) Rangeons le tableau dans l'ordre croissant des x_i puis calculons $\bar{x}_1$ et $\bar{y}_1$ qui est la moyenne des quatre premières colonnes ainsi $\bar{x}_2$ et $\bar{y}_2$ la moyenne du reste des colonnes.

Frais de publicité (x_i)	22	24	25	27	30	32	35	35
------------------------------	----	----	----	----	----	----	----	----

Taux d'occupation (y_j)	48	32	55	45	52	67	72	76
-----------------------------	----	----	----	----	----	----	----	----

$$\bar{x}_1 = \frac{22+24+25+27}{4} = \frac{98}{4} = 24,5 ; \bar{y}_1 = \frac{48+32+55+45}{4} = \frac{180}{4} = 45$$

$$\bar{x}_2 = \frac{30+32+35+35}{4} = \frac{132}{4} = 33 ; \bar{y}_2 = \frac{52+67+72+76}{4} = \frac{267}{4} = 66,75$$

- 4) Déterminons une équation de droite qui passe par les points G_1 et G_2 .

Soit $y = ax + b$; avec $a = \frac{\bar{y}_2 - \bar{y}_1}{\bar{x}_2 - \bar{x}_1}$ et $b = \bar{y}_1 - a\bar{x}_1$

$$a = \frac{66,75 - 45}{33 - 24,5} = \frac{21,75}{8,5} = 2,55 \text{ et } b = 45 - 2,55 \times 24,5 = -17,175 \text{ d'où } y = 2,55x - 17,175$$

- 5) Calculons $p = \frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{x} \bar{y} = \frac{13298}{8} - 28,75 \times 55,88 = 55,70$ $p = \text{cov}(x; y)$;

$$r = \frac{p}{\sqrt{V_x \times V_y}} = \frac{55,70}{\sqrt{21,94 \times 193,80}} = 0,86 . \text{ Il existe une forte corrélation entre les frais de publicité et le taux d'occupation des chambres de cet hôtel.}$$

- 6) Déterminons une équation de la droite de la forme $y = ax + b$; avec $a = \frac{p}{V_x} =$

$$\frac{55,70}{21,94} = 2,54 \text{ et } b = \bar{y} - a\bar{x} = 55,88 - 2,54 \times 28,75 = -17,14 \text{ donc } y = 2,54x - 17,14.$$

- 7) Si les frais de publicité étaient de 4000000francs, soit $x = 40$ (centaines de millions), alors la valeur estimative du taux d'occupation de l'hôtel serait: $y = 2,54 \times 40 - 17,14 = 84,46$.

RESUME :

Point moyen :

Soit $(x_i; y_i; n_{ij})$ ou $(x_i; y_i)$ une série statistique à deux caractères X et Y quantitatifs. X et Y est le caractère étudié sur une population d'effectif total N .

On appelle point moyen du nuage de points représentant cette série, le point G de coordonnées $G(\bar{x}; \bar{y})$ où $\bar{x}$ et $\bar{y}$ sont les moyennes des séries marginales de la série $(x_i; y_i; n_{ij})$.

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i \text{ et } \bar{y} = \frac{1}{N} \sum_{i=1}^N y_i$$

Caractéristique de dispersion :

Pour étudier la dispersion de chaque caractère X et Y . On peut calculer leurs variances :

$$V(x) = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2 = \frac{1}{N} \sum_{i=1}^N x_i^2 - (\bar{x})^2 \text{ et } V(y) = \frac{1}{N} \sum_{i=1}^N (y_i - \bar{y})^2 = \frac{1}{N} \sum_{i=1}^N y_i^2 - (\bar{y})^2$$

Covariance :

On appelle covariance de la série double $(x_i; y_i)$ le nombre noté $Cov(X; Y)$ tel que :

$$Cov(X; Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{x} \bar{y}$$

Coefficient de corrélation :

Le coefficient de corrélation est le nombre réel noté r qui est défini par $r = \frac{Cov(X; Y)}{\sigma_X \cdot \sigma_Y}$ où σ_X et σ_Y représentent respectivement l'écart-type de X et de Y .

Ajustement linéaire :

Lorsque les points du nuage semblent alignés autour d'une droite, on dit qu'on peut ajuster ce nuage à cette droite : ce type d'ajustement est appelé ajustement linéaire. Les résultats entre x et y sont de la forme $y = ax + b$ où $x = a'y + b'$.

Cette relation permet d'exprimer la valeur d'un caractère en fonction de l'autre. Il existe deux méthodes pour déterminer cette droite à savoir la méthode des moindres carrés et celle de MAYER

➤ Méthode des moindres carrés

La droite de régression de y **en** x est donnée par :

$$(D): y = ax + b \text{ avec } a = \frac{cov(x;y)}{V_x} \text{ et } b = \bar{y} - a\bar{x}.$$

La droite de régression de x **en** y est donnée par :

$$(D'): x = a'y + b' \text{ avec } a' = \frac{cov(x;y)}{V_y} \text{ et } b' = \bar{x} - a'\bar{y}$$

➤ Méthode de MAYER

Pour déterminer la droite de MAYER :

- 1) On partage la série statistique initiale rangée dans l'ordre croissant des x_i , en deux séries d'effectifs égaux si l'effectif total est pair, sinon on met le couple du milieu soit dans le premier soit dans le deuxième groupe.
- 2) On détermine les points moyens G_1 et G_2 de chaque groupe
- 3) La droite de MAYER est la droite passant par G_1 et G_2 .

Remarques :

- Le point moyen G appartient aux droites de régression (D) et (D') .
- On a toujours $-1 \leq r \leq 1$.
- Si $|r| = 1$, alors tous les points du nuage sont alignés sur les droites de régression linéaire (D) et (D') qui sont confondues : on dit que la corrélation linéaire entre les deux caractères est **parfaite**.

- Si $|r|$ est proche de 1 on dit qu'il y'a une **bonne** corrélation linéaire ou une **forte** corrélation linéaire entre les deux variables. En général on considère que la corrélation linéaire entre les deux variables est **forte** lorsqu'on a : $0,87 \leq |r| \leq 1$.

EXERCICES D'APPLICATIONS :

Le tableau suivant donne les résultats à partir de 10 essais de laboratoire concernant la charge de rupture d'un acier en fonction de sa teneur en carbone.

Teneur en carbone x_i	70	60	68	64	66	64	62	70	74	62
Charge de rupture y_i (en kg)	87	71	79	74	79	80	75	86	95	70

- 1) Représenter graphiquement le nuage de points de coordonnées $(x_i; y_i)$ dans le plan muni d'un repère orthonormé d'origine le point représentant le couple (60 ; 70) du tableau et l'unité graphique est le centimètre.
- 2) Calculer les coordonnées du point moyen G du nuage de points
- 3) Calculer le coefficient de corrélation ainsi que son interprétation de cette série.
- 4) Déterminer par la méthode de MAYER ainsi que par la méthode de moindre carrés une équation de la droite de régression de x en y .
- 5) Quelle estimation peut-on faire de la teneur en carbone si la charge de rupture est de 125kg ?